

【●】 ภาพรวมและจุดเด่นนวัตกรรม

Core Highlights & Value Proposition

ความจำเป็น: ในระบบ Big Data การตรวจจับปัญหาจาก Log ด้วย Regex แบบเดิมจับลำดับที่ผิดปกติไม่ได้ ขณะที่โมเดลแมชชีนเลิร์นนิงที่แข็งแกร่งกว่า LogWatchdog จึงผสาน 2 ขุมพลัง AI เพื่อแก้ปัญหาที่เฉพาะ

◆ 3 เสาหลักนวัตกรรมของ LogWatchdog

- Dual-Perspective Engine: ตรวจจับทั้งมิติความถี่ (Count Outlier) และมิติลำดับเวลา (Sequential Workflow)
- Cascaded Noise Suppression: ใช้ Isolation Forest เป็นตัวกรองช่วยตัด False Alarm จากเธรดสลัป
- White-Box Explainability: เจาะจงบรรทัดต้นเหตุ (Culprit Line) ดึงบริบท 5 บรรทัดมาแสดงทันที

◆ บทพิสูจน์เชิงตัวเลข (Benchmark Snapshot)

- ✓ Recall: 100.00% (ตรวจจับความผิดปกติได้ครบทุกเคส)
- ✓ Precision: 73.49% (สูงกว่า LSTM เดี่ยว +13.96%)
- ✓ F1-Score: 84.72% (ยกระดับสูงสุดในทุกการทดสอบ)
- ✓ False Alarms Cut: ลดลง 46.9% จาก 539 เหลือ 286

คุณค่าเชิงวิศวกรรม: ลดระยะเวลากู้คืนระบบ (MTTR) เหลือไม่ถึง 1 วินาที และตัดปัญหา Alert Fatigue ได้อย่างเด็ดขาด พร้อมทำงานรวดเร็วบน CPU ทั่วไป

【●】 ข้อมูลโครงการและคณะผู้จัดทำ

Project Team & Academic Credits

◆ ผู้พัฒนาโครงการ (Developer)

นายกรวิชัย คงคล้าย (Korawit Kongkhla)

รหัสนักศึกษา: 6710110006 | Section: 01

สาขาวิศวกรรมคอมพิวเตอร์ ภาควิชาวิศวกรรมคอมพิวเตอร์
คณะวิศวกรรมศาสตร์ มหาวิทยาลัยสงขลานครินทร์

◆ คณะอาจารย์ที่ปรึกษา (Advisors)

ดร. อนันท์ ชกสุริวงศ์

ดร. วรินทร์ โรจนกรินทร์

รายวิชา 240-318 AI&ML (ปีการศึกษา 2569/1)

◆ สถาปัตยกรรมและเทคโนโลยี (Tech Stack)

- Core AI: PyTorch (LSTM) + Scikit-learn (iForest)
- Log Parsing: Drain3 Template Miner (LogHub)
- Dashboard: Streamlit + Altair Data Visualization
- Quality: 37/37 Unit Tests ผ่าน 100% (pytest)

◆ ระบบทดสอบและสาธิตสด (Interactive Demo)

- Streamlit Web App: <http://localhost:8501>
- รองรับ Live Inference จำลอง 3 เคสจริง
- รายงาน Incident Report แบบ JSON / Markdown

อ้างอิง: DeepLog (ACM CCS 2017), Isolation Forest (IEEE ICDM 2008), LogHub Benchmark (ICSE 2019)

รายวิชา 240-318 AI&ML | สาขาวิศวกรรมคอมพิวเตอร์ ม.อ.

LogWatchdog

ระบบตรวจจับและระบุสาเหตุความผิดปกติใน System Logs

Hybrid Dual-Engine Architecture (Isolation Forest + DeepLog LSTM) with Cascaded Synergy

ยกระดับการตรวจจับและสืบสวน Incident ในระบบกระจายศูนย์ (Big Data & Distributed Clusters) ก้าวข้ามขีดจำกัดของ Regex แบบเดิมด้วย AI สองขุมพลัง

◆ จุดเด่นสำคัญระดับองค์กร (Core Values)

- ✓ Zero False Negatives: ตรวจจับได้ครบ 100.00% ไม่หลุดรอด
- ✓ Cascaded Noise Filter: ตัดการแจ้งเตือนพรั้งเพื่อลด 46.9%
- ✓ Root Cause Localization: ชี้เป้าบรรทัดปัญหาพร้อมบริบท 5 บรรทัด
- ✓ Ultra Lightweight: ทำงานระดับมิลลิวินาทีบน CPU มาตรฐาน

◆ เหมาะสำหรับผู้ใช้งาน (Target Users)

- วิศวกรดูแลระบบ (Site Reliability Engineers - SREs)
- ทีม DevOps และ Cloud Infrastructure Engineers
- ผู้ดูแลคลัสเตอร์ประมวลผลขนาดใหญ่ (HDFS, Kubernetes)

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์
มหาวิทยาลัยสงขลานครินทร์ วิทยาเขตหาดใหญ่

【●】 ปัญหาของการวิเคราะห์เดิม

The Big Challenge & Pain Points

System Event Logs เป็นแหล่งความจริงเชิงประจักษ์ (Ground Truth) เพียงแหล่งเดียวในระบบคอมพิวเตอร์ แต่วิศวกรต้องเผชิญกับ 4 อุปสรรควิกฤต:

1. ข้อมูลมหาศาล (Massive Volume)

คลัสเตอร์ Big Data ผลิต Log หลายล้านบรรทัด/ชม. การตรวจสอบด้วยสายตามนุษย์ (Manual) เป็นไปไม่ได้

2. Regex & Keyword ล้มเหลว (Brittle)

การค้นหาคำว่า 'Error' หรือ 'Failed' จับเคสลับลำดับไม่ได้ เช่น คำสั่งลบไฟล์เกิดขึ้นก่อนเขียนเสร็จ แม้คำสั่งจะถูกตามไวยากรณ์และไม่มีคำว่า Error ปรากฏเลยก็ตาม

3. ภาวะแจ้งเตือนล้นเกิน (Alert Fatigue)

โมเดลทั่วไปแจ้งเตือนพร่ำเพรื่อเมื่อเธรดสลับที่เล็กน้อย ทำให้วิศวกรเกิดความล่าและมองข้ามวิกฤตจริงไป

4. ขาดการชี้เป้า (Black-box Invisibility)

โมเดลส่วนใหญ่บอกแค่ 'ผิดปกติ' แต่ไม่บอกบรรทัดไหน ที่มันต้องเสียเวลาค้นหาต้นตอแบบสุ่ม (MTTR สูง)

สรุปปัญหา: ความผิดปกติในระบบมี 2 มิติที่ต้องตรวจจับพร้อมกัน: มิติความถี่ (Volumetric Outliers) และ มิติลำดับขั้นตอน (Sequential Path Permutations)

【●】 สถาปัตยกรรม Hybrid Dual-Engine

At Core & Cascaded Synergy

◆ 5-Brick Modular Workflow

- B1 (Ingestion): สตรีม Log ดิบ กรองและจัดกลุ่มตาม Block ID
- B2 (Drain3 Parser): สกัดแม่พิมพ์ข้อความ แมปสู่ Event ID
- B3 (Features): สกัด Count Vector และ Sliding Window (w=3)
- B4 (Hybrid Core): รวม 2 ขุมพลัง AI ผ่าน Cascaded Synergy
- B5 (Explainer): ระบุ Culprit Line และดึงบริบท 5 บรรทัด

◆ 2 ขุมพลัง AI ที่ทำงานร่วมกัน

Engine 1: Isolation Forest (100 iTrees, contamination 0.10)

ตรวจจับความผิดปกติเชิงความถี่และปริมาณ (Count Outlier)

Engine 2: DeepLog 2-Layer LSTM (Embed 32, Hidden 32)

ตรวจจับไวยากรณ์ลำดับการทำงานด้วยกฎ Top-K = 3

◆ กลไกตัดสินใจ Cascaded Synergy

- Sequence Gate: หาก LSTM ปกติ (0 violations) → สรุป Normal
- Severity Rule: หาก LSTM ผิดปกติรุนแรง (≥ 3 violations) หรือ iForest พ้องว่าความถี่ผิดปกติ → สรุป Anomaly
- Noise Suppressor: หาก LSTM พบ 1-2 violations แต่ iForest ยืนยันความถี่ปกติสมบูรณ์ → ปรับเป็น Normal (ตัด False Alarm ทั้ง!)

ผลสำเร็จ: กลไกนี้ทำให้ระบบคงค่า Recall 100.00% ไว้ได้ พร้อมลด False Alarm ลงได้ถึง 46.9%!

【●】 ผลการทดสอบเชิงประจักษ์ & แดชบอร์ด

Empirical Evaluation & Web App

Benchmark: ประเมินผลบนชุดทดสอบมาตรฐาน HDFS 2,793 เซสชัน:

โมเดล	Recall	Prec.	F1	FP (लग)
iForest	28.25%	55.72%	37.49%	179
DeepLog	100.00%	59.53%	74.64%	539
Hybrid (เรา)	100.00%	73.49%	84.72%	286 (-47%)

◆ นิติวิทยาศาสตร์ชี้เป้า (DeepLogExplainer)

- ระบุ Culprit Line แม่นยำ: เช่น writeBlock received exception
- สกัด Context Window: แสดง 5 บรรทัดแวดล้อมก่อนและหลังจุดเกิดเหตุ
- แจกแจง Probability Distribution: แสดง Top-K คาดการณ์ vs Actual

◆ Streamlit Web Application (4 แท็บพร้อมใช้งาน)

- Model Comparison: ดูกราฟแท่งเปรียบเทียบ 3 โมเดลสด
- Forensics & Timeline: สืบสวนลำดับเหตุการณ์และชี้เป้าบรรทัดปัญหา
- Live Playground: จำลองเคส Nominal, Fault, Permutation
- Architecture Blueprint: แผนผัง Lego 5 บล็อกแบบ Interactive

พร้อมใช้งานผ่านคำสั่ง: ./run_demo.sh หรือ streamlit run app.py